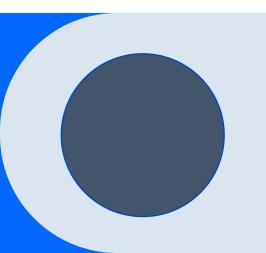
## 機器學習\_服裝辨識



08160971 黃凱勵 08160422 孫振寧 08160723 鄧晨言 08160130 林采葳

### 目錄

- 1. 研究動機
- 2. 研究方法
- 3. 實驗
- 4. 參考文獻



#### 研究動機

一開始在選擇題目的時候參考網路上很多的應用,發現很多的例子,像

是手寫辨識、地價預測.......等等的,其中服裝辨識對我們而言是相對好

理解的,因此我們最後決定做服裝辨識。

## 研究方法

### 資料

透過MNIST的數據庫讀取資料,

採用分類的方式,將服裝分為10類,

分別為T恤/上衣、褲子、套頭衫、禮服、

外套、涼鞋、襯衫、運動鞋、包包靴子、長靴

#### 資料

#### 標籤

- 0 T-shirt/top:T恤/上衣
- 1 Trouser: 褲子
- 2 Pullover: 套頭衫
- 3 Dress: 禮服
- 4 Coat:外套
- 5 Sandal:涼鞋
- 6 Shirt: 襯衫
- 7 Sneaker: 運動鞋
- 8 Bag:包包袋子
- 9 Ankle boot: 長靴

#### 屬性

服飾的特徵

每個點的灰階資料



### 模型

- 1. Sequential模型
- 2. 用來構建深度神經網絡

第一層是Flattening layer(展平層),第二層為全連接層,並設

置128個神經元,第三層則輸出10維的向量,分別代表這張

圖片屬於 0 到 9 的機率

#### 優化器

接下來選擇優化器,我們使用'Adam'優化器,一般而言比

SGD模型(隨機梯度下降法)成本低。



#### 損失函數

損失函數爲' sparse\_categorical\_crossentropy',就是**交叉熵**,而 categorical\_crossentropy 和 sparse\_categorical\_crossentropy這二者都是針對多分類任務。

差別在於輸入參數形式上的區別,在 loss 的計算在本質上沒有區別

#### 成效衡量指標

成效衡量指標則是'accuracy'

(tp+tn)/(tp+fp+fn+tn)

|                 |          | True Class                      |                                 |  |
|-----------------|----------|---------------------------------|---------------------------------|--|
|                 |          | Positive                        | Negative                        |  |
| Predicted Class | Positive | True<br>Positive<br>Count (TP)  | False<br>Positive<br>Count (FP) |  |
|                 | Negative | False<br>Negative<br>Count (FN) | True<br>Negative<br>Count (TN)  |  |



### 訓練數據(epochs)的設置

通常,epochs 越大,最後訓練的損失值會越小,但是訓練次

數過大,會導致過擬合的現象。

```
model.compile(optimizer = tf.keras.optimizers.Adam(),
                   #編譯模型 優化函數
    loss = 'sparse_categorical_crossentropy',
                   #遺失函數
    metrics=['accuracy'])
                    #正確率
                   #訓練5個訓練集
model.fit(training images, training labels, epochs=5)
Epoch 1/5
Epoch 2/5
Epoch 3/5
Epoch 4/5
Epoch 5/5
```

### 訓練數據(epochs)的設置

將epochs 設為50,訓練50次訓練集,從測試集劃分80%給訓

練集,測試的間隔為20次

```
model.compile(optimizer = tf.keras.optimizers.Adam(),
                      #編譯模型 優化函數
     loss = 'sparse categorical crossentropy',
                      #遺失函數
     metrics=['accuracy'])
                      #正確率
model.fit(training images, training labels, epochs=50, validation split=0.2, validation freq=20)
Epoch 1/50
Epoch 40/50
0.8926
Epoch 20/50
0.8908
Epoch 50/50
```

# 實驗1



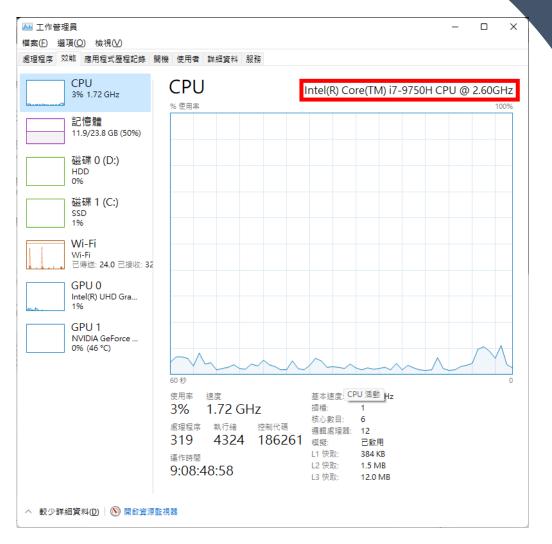
### 實驗平台



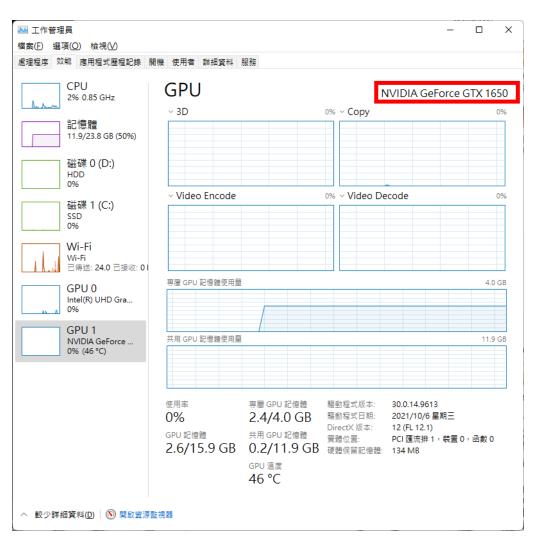
- 1. 使用 python 進行程式的撰寫。
- 2. 能夠把**軟體代碼、計算輸出、解釋文檔、多 媒體資源**整合在一起的多功能科學運算平台。
- 3. 不需要切換窗口去找資料,只要看一個文件, 就可以獲得項目的所有信息。
- 4. 每次實驗可以只跑一小個 Cell 裡的代碼,在 代碼下面**立刻**就可以**看到结果**。

### 實驗環境





### 實驗環境



### 實驗函式庫簡介

#### import tensorflow as tf

用於**機器學習和深度神經網路方面** 的研究

#### import tkinter as tk

用來在 Python 中**建構 GUI 圖形介** 面程式

#### from tkinter import filedialog

開啟**檔案對話框**用法

import tensorflow as tf
import tkinter as tk

from tkinter import filedialog
import matplotlib.pyplot as plt
import numpy as np
import random

#### import matplotlib.pyplot as plt

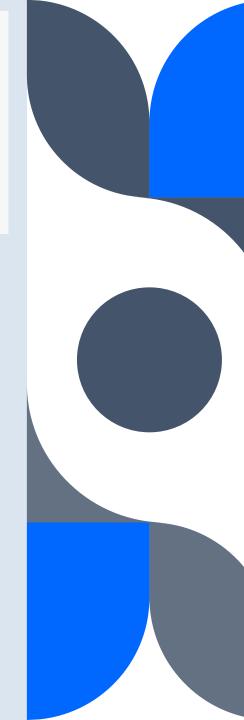
用來繪圖、圖表呈現及數據表示

#### import numpy as np

支援**大量的維度陣列與矩陣運算**,也針對陣列 運算提供大量的數學函式庫

#### import random

**匯入**標準模組庫中(standard library) 的**亂數模組(random)** 



### 實驗資料來源

訓練資料與測試資料數量皆為MNIST數據庫

```
mnist = tf.keras.datasets.fashion_mnist

(training_images, training_labels),(test_images,test_labels) = mnist.load_data()
```

### 實驗資料筆數

訓練資料數量 有 60000 張 28\*28大小的圖片

測試資料數量 有 10000 張 28\*28大小的圖片

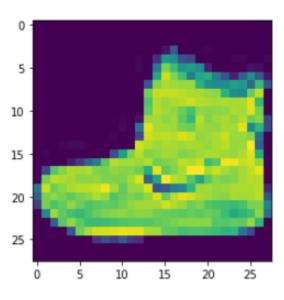
```
print( 'training_image' + str(training_images.shape)) #資料大小
print( 'training_label' + str(training_labels.shape))
print( 'test_image' + str(test_images.shape))
print( 'test_label' + str(test_labels.shape))

training_image(60000, 28, 28)
training_label(60000,)
test_image(10000, 28, 28)
test_label(10000,)
```

```
import tensorflow as tf
                                                     #匯入模型
import tkinter as tk
from tkinter import filedialog
import matplotlib.pyplot as plt
import numpy as np
import random
mnist = tf.keras.datasets.fashion_mnist
(training_images, training_labels),(test_images,test_labels) = mnist.load_data()
print( 'training_image' + str(training_images.shape)) #資料大小
print( 'training label' + str(training labels.shape))
print( 'test image' + str(test images.shape))
print( 'test label' + str(test labels.shape))
training_image(60000, 28, 28)
training label(60000,)
test image(10000, 28, 28)
test label(10000,)
```

```
取前16張圖來檢查處理過的資料是否正常可顯示
for num in range(0,16):
    plt.subplot(4,4,num+1)
    plt.title('[%d]Label: %d' % (num,training_labels[num]))
    plt.imshow(training_images[num],
                                           cmap=plt.get_cmap('gray_r'))
plt.tight_layout()
plt.show()
 [0]Label: 9
               [1]Label: 0
                             [2]Label: 0
                                           [3]Label: 3
               [5]Label: 2
                             [6]Label: 7
                                           [7]Label: 2
 [4]Label: 0
                                             0
               [9]Label: 5
                            [10]Label: 0
                                          [11]Label: 9
 [8]Label: 5
               25
 [12]Label: 5
               [13]Label: 5
                            [14]Label: 7
                                          [15]Label: 9
               25
```

```
plt.imshow(training images[0])
                                 #訓練圖
def printMatrixE(a):
    rows = a.shape[0]
                                        以第一張圖為例
   cols = a.shape[1]
   for i in range (0, rows):
       str1=""
                                        顯示每行每列的特徵值(圖像的RGB值)
       for j in range(0,cols):
           str1=str1+("%3.0f" % a[i,j])
       print(str1)
   print("")
printMatrixE(training images[0])
                                                                        0102204176134144123 23
                                                                        0155236207178107156161109 64 23 77130 72 15
                                                                     0 69207223218216216163127121122146141 88172 66
                                                                     0200232232233229223223215213164127123196229
                                                                     0183225216223228235227224222224221223245173
                                                                     0193228218213198180212210211213223220243202 0
                                                                  0 12219220212218192169227208218224212226197209 52
                                                                  0 9924422220218203198221215213222220245119167 56
                                                                  0 55236228230228240232213218223234217217209 92 0
                                                                  0237226217223222219222221216223229215218255 77
                                                         0 62145204228207213221218208211218224223219215224244159
                                           0 18 44 82107189228220222217226200205211230224234176188250248233238215
                                  0 57187208224221224208204214208209200159245193206223255255221234221211220232246
                                  3202228224221211211214205205205220240 8015025522922118815419121020420922222825
                                 98233198210222229229234249220194215217241 65 73106117168219221215217223223224229 29
                                 75204212204193205211225216185197206198213240195227245239223218212209222220221230 67
                                 48203183194213197185190194192202214219221220236225216199206186181177172181205206115
                                  0122219193179171183196204210213207211210200196194191195191198192176156167177210 92
                                       74189212191175172175181185188189188193198204209210210211188188194192216170
```



間,總和等於1,適合多分類使用

```
由於灰階影像的值是0~255,所以我們可以選擇
training images = training images / 255.0
                               全數除以255.0來等比例縮小
test_images = test_images / 255.0
model = tf.keras.models.Sequential([tf.keras.layers.Flatten(),
                         tf.keras.layers.Dense(128, activation=tf.nn.relu),
                         tf.keras.layers.Dense(10, activation=tf.nn.softmax)])
建立模型(Model):
確立Input格式 => Sequential()
要經過幾層處理 =>3層
每一層要作什麼處理
第一層=>Flattening layer(展平層),
第二層=>全連接層,設置128個神經元,激活函數為非線性激活函數(ReLU函數)。
此模型輸入一個向量(為校正點中心的 28*28 服飾圖片)
第三層=>輸出 10 維的向量,分別代表這張圖片屬於 0 到 9 的機率,且機率值介於 [0,1] 之
```

確立目標及求解方法:以compile函數 定義損失函數(loss)、

```
model.compile(optimizer = tf.keras.optimizers.Adam(), 優化函數(Optimizer)及
loss = 'sparse_categorical_crossentropy',
metrics=['accuracy'])

成效衡量指標(mertrics)

model.fit(training_images, training_labels, epochs=50, validation_split=0.2, validation_freq=20)
```

#### 訓練50個訓練集,從測試集劃分80%給訓練集,測試的間隔為20次

#### print(model.summary()) 顯示目前網路架構

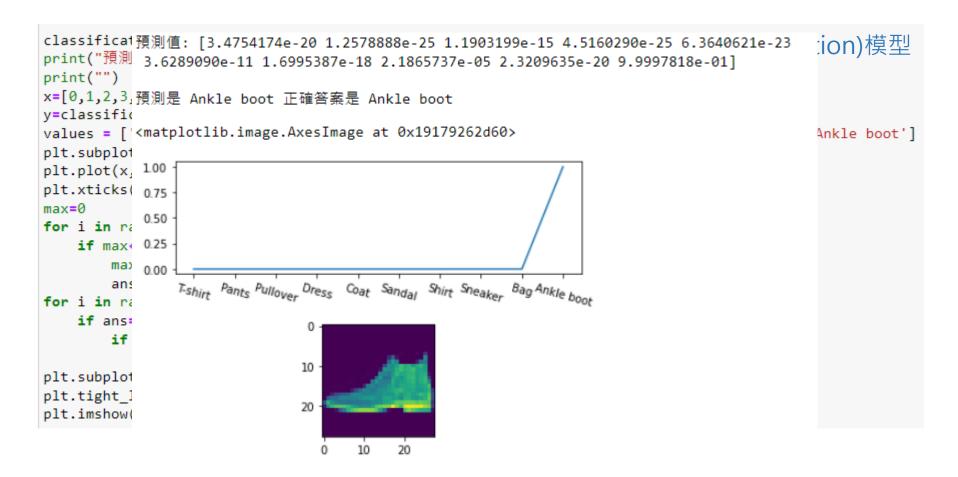
Model: "sequential"

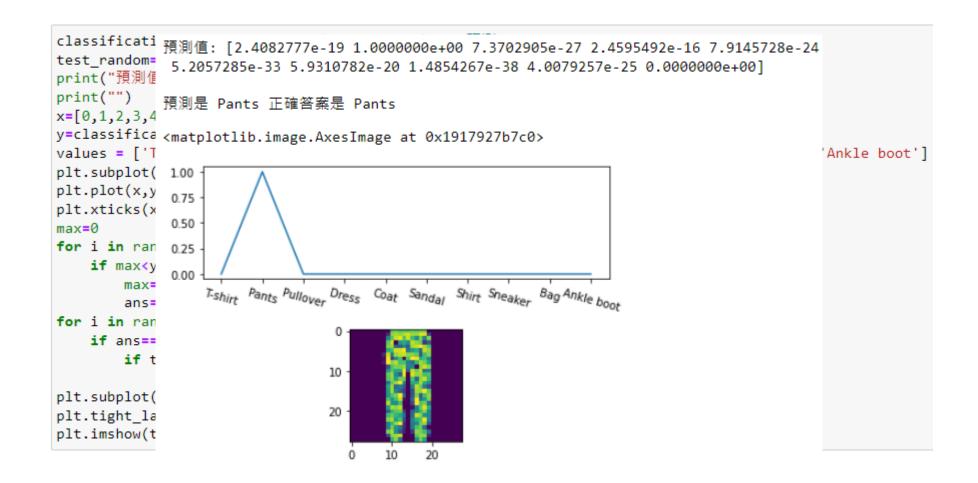
| Output Shape | Param #                |
|--------------|------------------------|
| (32, 784)    | 0                      |
| (32, 128)    | 100480                 |
| (32, 10)     | 1290                   |
|              | (32, 784)<br>(32, 128) |

\_\_\_\_\_

Total params: 101,770 Trainable params: 101,770 Non-trainable params: 0

None





### 實驗不同參數下的結果

● 改變神經元數量

```
model = tf.keras.models.Sequential([tf.keras.layers.Flatten(),
                   tf.keras.layers.Dense(512, activation=tf.nn.relu),
                   tf.keras.layers.Dense(10, activation=tf.nn.softmax)])
Epoch 1/50
Epoch 20/50
0.8931
Epoch 40/50
0.8925
Epoch 50/50
```

## 實驗2



## 研究方法

### 資料

透過MNIST的數據庫讀取資料,

採用分類的方式,將服裝分為10類,

分別為T恤/上衣、褲子、套頭衫、禮服、

外套、涼鞋、襯衫、運動鞋、包包靴子、長靴

#### 資料

#### 標籤

- 0 T-shirt/top:T恤/上衣
- 1 Trouser: 褲子
- 2 Pullover: 套頭衫
- 3 Dress: 禮服
- 4 Coat:外套
- 5 Sandal:涼鞋
- 6 Shirt:襯衫
- 7 Sneaker: 運動鞋
- 8 Bag:包包袋子
- 9 Ankle boot: 長靴

#### 屬性

服飾的特徵

每個點的灰階資料



#### 模型

- 1.RNN模型循環神經網絡
- 2. output 不只受上一層輸入的影響,也受到同一層前一個 output 的影響

```
model = keras.Sequential([
    keras.layers.SimpleRNN(
    input_shape=(28, 28),
    units=256,
    unroll=True),
    keras.layers.Dropout(rate=0.2),
    keras.layers.Dense(10, activation=tf.nn.softmax)
])
```

#### 優化器

接下來選擇優化器,我們使用' AdamOptimizer()'優化器,

隨機梯度下降算法的擴展式,近來其廣泛用於深度學習應用

中,尤其是計算機視覺和自然語言處理等任務。

## AdamOptimizer()

• 適應性梯度算法(AdaGrad)可以每一個參數保留一個學習 習率以提升在稀疏梯度上的性能。

 均方根傳播(RMSProp)基於權重梯度最近量級的均值為 每一個參數適應性地保留學習率。

#### 損失函數

損失函數爲' sparse\_categorical\_crossentropy',就是**交叉熵**,而 categorical\_crossentropy 和 sparse\_categorical\_crossentropy這二者都是針對多分類任務。

差別在於輸入參數形式上的區別,在 loss 的計算在本質上沒有區別

#### 成效衡量指標

成效衡量指標則是'accuracy'

(tp+tn)/(tp+fp+fn+tn)

| •               |          | True Class                      |                                 |
|-----------------|----------|---------------------------------|---------------------------------|
|                 |          | Positive                        | Negative                        |
| Predicted Class | Positive | True<br>Positive<br>Count (TP)  | False<br>Positive<br>Count (FP) |
|                 | Negative | False<br>Negative<br>Count (FN) | True<br>Negative<br>Count (TN)  |

# 實驗2



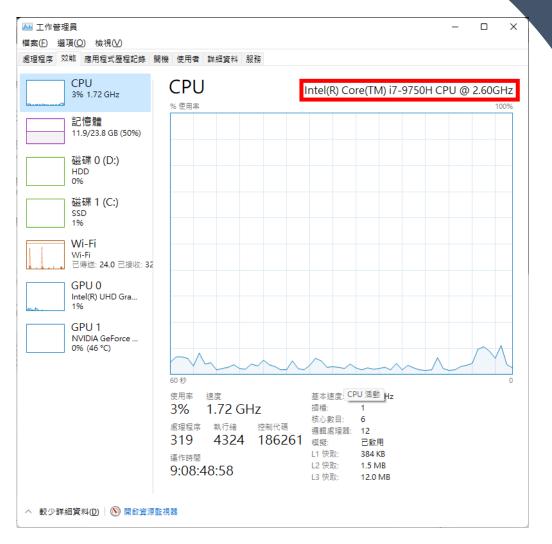
### 實驗平台



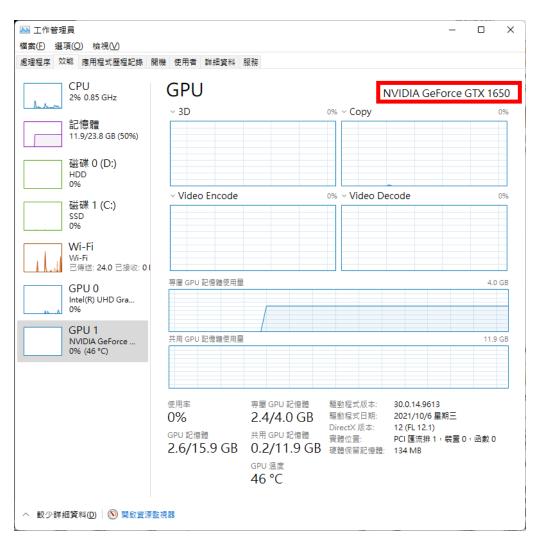
- 1. 使用 python 進行程式的撰寫。
- 2. 能夠把**軟體代碼、計算輸出、解釋文檔、多 媒體資源**整合在一起的多功能科學運算平台。
- 3. 不需要切換窗口去找資料,只要看一個文件, 就可以獲得項目的所有信息。
- 4. 每次實驗可以只跑一小個 Cell 裡的代碼,在 代碼下面**立刻**就可以**看到结果**。

### 實驗環境





### 實驗環境



### 實驗函式庫簡介

#### import tensorflow as tf

用於**機器學習和深度神經網路方面** 的研究

#### import tkinter as tk

用來在 Python 中**建構 GUI 圖形介 面**程式

#### from tkinter import filedialog

開啟**檔案對話框**用法

import tensorflow as tf
import tkinter as tk

from tkinter import filedialog
import matplotlib.pyplot as plt
import numpy as np
import random

#### import matplotlib.pyplot as plt

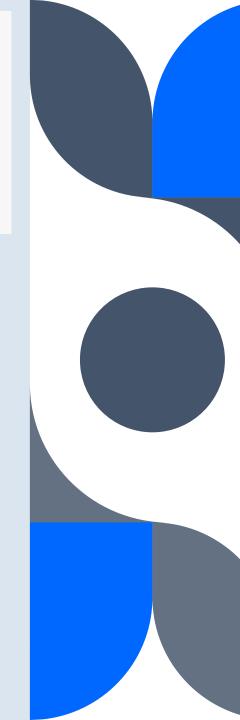
用來繪圖、圖表呈現及數據表示

#### import numpy as np

支援**大量的維度陣列與矩陣運算**,也針對陣列 運算提供大量的數學函式庫

#### import random

**匯入**標準模組庫中(standard library) 的**亂數模組(random)** 



```
In [1]:

from tensorflow import keras
import tensorflow as tf
import tkinter as tk

from tkinter import filedialog
import matplotlib.pyplot as plt
import numpy as np
import random
import os
os.environ["KMP_DUPLICATE_LIB_OK"]="TRUE"
```

在windows顯示圖像的時候可能會遇到一個錯誤,

需要添加這個語句才可以正常通過,

意思是允許重複加載動態鏈接庫

#### 訓練資料與測試資料數量皆為MNIST數據庫

In [3]: EAGER = True 計算時會先展開結構

Dropout可以作為訓練深度神經網路的一種方法。 在每個訓練中,通過忽略一半的特徵檢測器(讓一半的隱層節點值為0),可以明顯地減少過擬合現象。 這種方式可以減少特徵檢測器(隱層節點)間的相互作用

```
In [5]: training_images = training_images / 255.0
test_images = test_images / 255.0
```

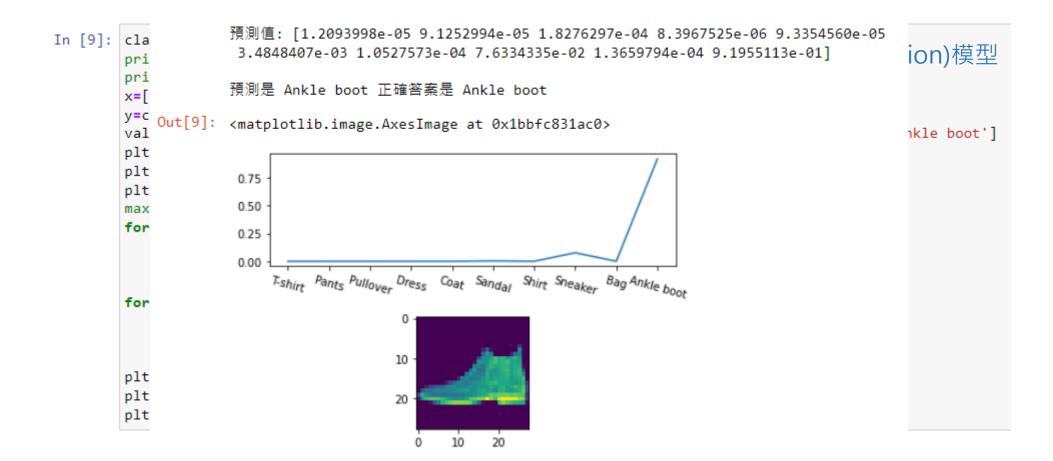
由於灰階影像的值是0~255,所以我們可以選擇 全數除以255.0來等比例縮小

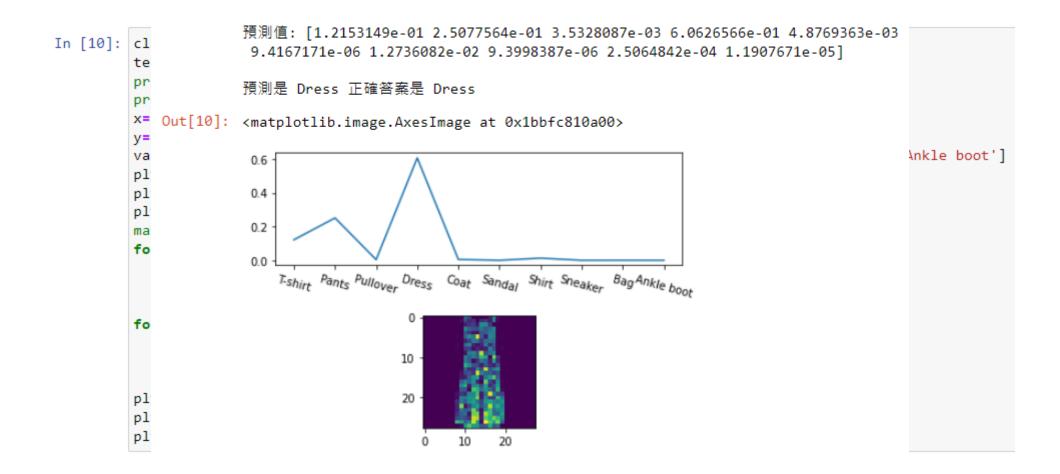
#### Learning\_rate

學習速率,值越大則表示權值調整動作越大

```
In [6]: lr = 0.001
                                      訓練數據 (epochs) 的設置 = 20
    epochs = 20
    model.compile(optimizer=tf.compat.v1.train.AdamOptimizer(lr),
           loss='sparse categorical crossentropy',
           metrics=['accuracy'])
    model.fit(training_images, training_labels, epochs=epochs, validation_data=[test_images[:1000], test_labels[:1000]])
Epoch 1/20
0.8110
Epoch 9/20
0.8410
Epoch 20/20
0.7910
```

```
print(model.summary())
                           顯示目前網路架構
Model: "sequential"
 Layer (type)
                             Output Shape
                                                      Param #
 simple rnn (SimpleRNN)
                             (None, 256)
                                                      72960
 dropout (Dropout)
                             (None, 256)
                                                      0
 dense (Dense)
                             (None, 10)
                                                      2570
Total params: 75,530
Trainable params: 75,530
Non-trainable params: 0
None
```



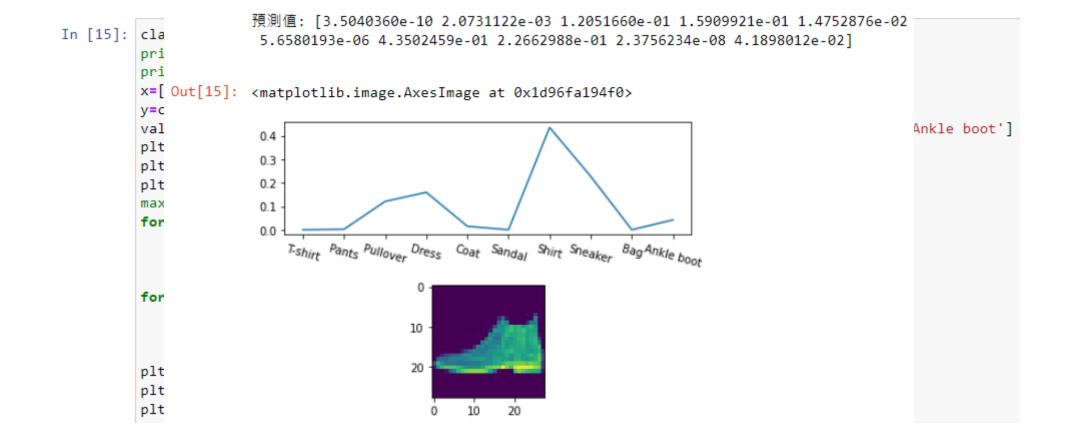


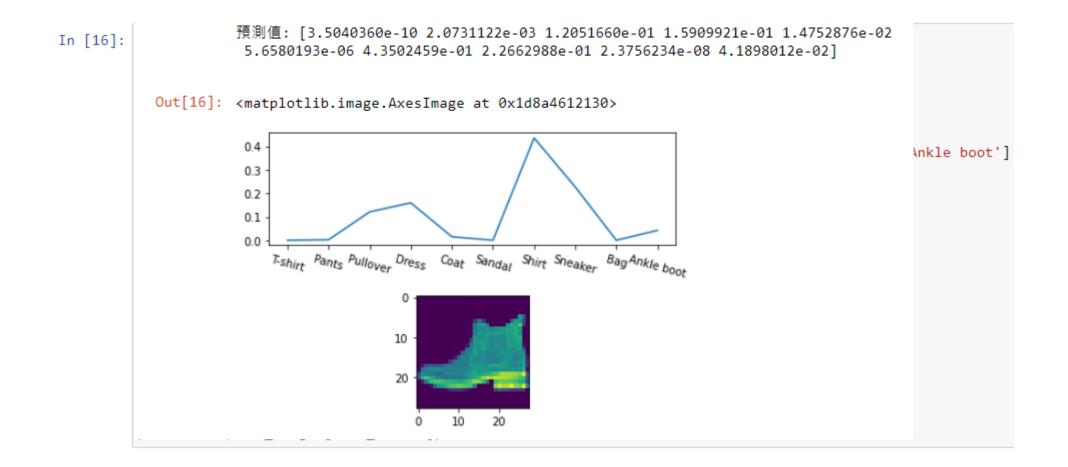
### 實驗不同參數下的結果

● 改變神經元數量

```
In [12]: 1r = 0.05
   epochs = 5
   model.compile(optimizer=tf.compat.v1.train.AdamOptimizer(lr),
        loss='sparse categorical crossentropy',
        metrics=['accuracy'])
   model.fit(training_images, training_labels, epochs=epochs, validation_data=[test_images[:1000],test_labels[:1000]])
   Epoch 1/5
   y: 0.0870
   Epoch 2/5
   0.0970
   Epoch 3/5
   0.1110
   Epoch 4/5
   0.1070
   Epoch 5/5
   0.0970
```

```
In [17]: print(model.summary())
       Model: "sequential"
        Layer (type)
                               Output Shape
                                                    Param #
        simple_rnn (SimpleRNN)
                                                    276992
                               (None, 512)
        dropout (Dropout)
                               (None, 512)
                                                    0
        dense (Dense)
                               (None, 10)
                                                    5130
       Total params: 282,122
       Trainable params: 282,122
       Non-trainable params: 0
       None
In [14]: model.evaluate(test_images, test_labels) #測試
       Out[14]: [7.12483024597168, 0.10000000149011612]
```





## 謝謝大家